

[KNN] Projekt - extrakce metadat vědeckých článků

David Machů (*xmachu05*), Matěj Neděla (*xnedel11*)

Řešený problém

Projekt se zaměřuje na extrakci metadat z titulních stran vědeckých článků. Cílem je s pomocí existujících řešení poloautomaticky připravit datovou sadu obsahující název, autory, abstrakt, klíčová slova a instituce a následně natrénovat destilovanou neuronovou síť, která bude schopna tyto informace extrahovat z obrazové podoby titulní strany článku.

Existující řešení

GROBID (*GeneRation Of Bibliographic Data*)

- aktivní projekt
- **výstup:** název, autoři (včetně e-mailů a institucí), abstrakt, klíčová slova, datum vydání, ...
- **výhody:** rychlé zpracování
- **nevýhody:** vyžaduje nativní PDF
- **GitHub repozitář:** <https://github.com/grobidOrg/grobid>

CERMINE (*Content ExtRactor and MINEr*)

- neaktivní projekt (poslední úpravy v roce 2018)
- **výstup:** název, autoři (včetně e-mailů a institucí), abstrakt, klíčová slova, datum vydání, ...
- **nevýhody:** vyžaduje nativní PDF, pomalé zpracování
- **GitHub repozitář:** <https://github.com/CeON/CERMINE>

Gemini, ChatGPT, ...

- **výstup:** flexibilní
- **výhody:** podpora obrazového PDF, rychlé zpracování

Vstupní data

Titulní strana vědeckého článku v obrazové podobě, typicky ve formátu PNG.

Výstupní data

Strukturovaná data ve formátu JSON, obsahující následující položky:

- název (*title*)
- autoři (*authors*) — jméno (*firstName*), příjmení (*lastName*), e-mail (*email*), instituce (*institution*)
- abstrakt (*abstract*)
- klíčová slova (*keywords*)
- datum vydání (*date*)

Testovací datová sada

Kaggle arXiv Dataset

Datová sada obsahující metadata všech vědeckých článků publikovaných na arXiv.org. Samotná PDF nejsou součástí datové sady, ale jsou jednoduše dostupná skrz URL <https://arxiv.org/pdf/{id}>.

- **počet záznamů:** 2.9 milionů
- **velikost metadat:** 5.1 GB
- **odkaz:** <https://www.kaggle.com/datasets/Cornell-University/arxiv>

```
{
  "id": "0704.0002",
  "submitter": "Louis Theran",
  "authors": "Ileana Streinu and Louis Theran",
  "title": "Sparsity-certifying Graph Decompositions",
  "comments": "To appear in Graphs and Combinatorics",
  "journal-ref": null,
  "doi": null,
  "report-no": null,
  "categories": "math.CO cs.CG",
  "license": "http://arxiv.org/licenses/nonexclusive-distrib/1.0/",
  "abstract": "We describe a new algorithm, the  $(k, \ell)$ -pebble game with colors, ...",
  "versions": [
    { "version": "v1", "created": "Sat, 31 Mar 2007 02:26:18 GMT" },
    { "version": "v2", "created": "Sat, 13 Dec 2008 17:26:00 GMT" }
  ],
  "update_date": "2008-12-13",
  "authors_parsed": [
    ["Streinu", "Ileana", ""],
    ["Theran", "Louis", ""]
  ]
}
```

Získání datové sady

Pro získání dat byl implementován samostatný skript v jazyce Python. Nástroj umožňuje parametrizaci rozsahu stahování (počet dokumentů a počáteční index), což zajišťuje rozšiřitelnost sady v budoucí fázi projektu. Vědecké články jsou čerpány ze serveru arXiv.org, přičemž proces stahování zahrnuje kromě uložení původního PDF souboru i extrakci titulní strany do formátu PNG a následnou serializaci metadat do formátu JSON. Implementace respektuje limity serveru arXiv.org, tedy omezení na 1 požadavek za 3 sekundy. Toto omezení představuje hlavní úzké hrdlo procesu a limituje celkovou rychlost stahování. Ukázka jednoho záznamu metadat je uvedena níže.

```
{
  "idx": 1,
  "id": "0704.0002",
  "title": "Sparsity-certifying Graph Decompositions",
  "authors": [
    { "firstName": "Ileana", "lastName": "Streinu", "email": null, "institution": null },
    { "firstName": "Louis", "lastName": "Theran", "email": null, "institution": null }
  ],
  "abstract": "We describe a new algorithm, the  $(k, \ell)$ -pebble game with colors, ...",
  "keywords": null,
  "date": "2008-12-13"
}
```

Dále by bylo vhodné doplnit chybějící parametry (e-mail a instituce autorů, klíčová slova) pomocí existujících řešení (např. GROBID) a dostupných nativních PDF dokumentů.

Předzpracování datové sady

Před samotným trénováním byla datová sada převedena do formátu očekávaného frameworkem Qwen-VL-Series-Finetune¹. Python skript načtl zdrojová metadata ze souboru a ke každému záznamu přiřadil odpovídající obrázek první strany článku ve formátu PNG. Pro každý vzorek byl vytvořen vstup tvořený instrukcí pro extrakci metadat a referenční výstup ve formátu JSON obsahující název článku, seznam autorů, abstrakt a klíčová slova.

¹<https://github.com/2U1/Qwen-VL-Series-Finetune>

```
{
  "id": "0704.0002",
  "image": "0704.0002.png",
  "conversations": [
    { "from": "human", "value": "<image>\nExtract metadata from this first page of a ..." },
    { "from": "gpt", "value": "{ \"title\": \"Sparsity-certifying Graph ...\" }" }
  ]
}
```

Trénování neuronové sítě

Pro trénování byl použit framework Qwen-VL-Series-Finetune¹ a jako základní model byl zvolen Qwen2.5-VL-3B-Instruct. Učení probíhalo na výpočetním clusteru prostřednictvím skriptu, který zajistil přípravu pracovního prostředí, přesun dat na lokální prostor a spuštění trénovacího skriptu. Model byl doladován metodou LoRA, která umožňuje efektivní adaptaci velkého předtrénovaného modelu při nižších paměťových i výpočetních nárocích. Pro trénování modelu bylo použito přibližně 16 000 vědeckých článků. Vstupem byly obrázky jejich titulních stran a cílem modelu bylo generovat metadata v definovaném JSON schématu.

Experimenty a vyhodnocení

První experiment byl zaměřen na porovnání přesnosti základního modelu (konkrétně Qwen2.5-VL-3B-Instruct) a jeho *fine-tuned* varianty z předešlého kroku. Testovacím prostředím bylo Metacentrum poskytované organizací CESNET a výpočetní cluster s GPU o minimální kapacitě 16 GB VRAM. Datová sada pro testování obsahovala 200 náhodně vybraných záznamů, které nebyly použity během tréninku. Výsledky prvního experimentu jsou shrnuty v následující tabulce. Hodnoty jednotlivých metrik představují průměr ze všech záznamů, které daný model úspěšně zpracoval, tedy pro které vygeneroval validní JSON.

	Time <i>average</i>	Valid JSON <i>count (ratio)</i>	Title <i>Levenshtein d.</i>	Authors <i>F1 score</i>	Abstract <i>Rouge-L score</i>
Base model	1.565 s	164 (82 %)	0.985	0.205	0.899
Tuned model	2.381 s	192 (96 %)	0.990	0.862	0.929

Podobnost názvu je měřena pomocí Levenshteinovy vzdálenosti, která kvantifikuje počet editací potřebných k transformaci jednoho řetězce na druhý, resp. pomocí její normalizované varianty. Pro vyhodnocení autorů je použito F1 skóre, které počítá harmonický průměr přesnosti (*precision*) a úplnosti (*recall*). Abstrakt je hodnocen pomocí Rouge-L skóre, které měří nejdelší společnou podposloupnost (LCS) mezi predikovaným a referenčním abstraktem.

Oproti základnímu modelu má náš *fine-tuned* model vyšší úspěšnost v generování validních JSON struktur o 14 procentních bodů. Rozdíly v přesnosti extrakce názvu jsou zanedbatelné. U extrakce autorů je významný rozdíl v úspěšnosti *fine-tuned* modelu, což je ale zapříčiněno především tím, že základní model často generoval autory ve špatném formátu.

GitHub repozitář

<https://github.com/nedelamatej/knn-mis>